Audit et fiabilisation du système de recommandation agricole AgriTrust

Projet personnel technique du parcours Data Scientist Machine Learning

Auteur	Baptiste Bonnet
Projet audité	Agritech Answers
Version	Version OpenClassrooms
Date	17 septembre 2026
Dépôt	github.com/baptiste-bonnet/agritrust-portfolio

Conclusion principale

Le modèle estime correctement le rendement sur le jeu de test, mais le classement des cultures n'est ni personnalisé ni assez robuste pour guider seul une décision agronomique.

Sommaire

1 Synthèse décisionnelle

2 Contexte et besoins métiers

3 Périmètre et méthode d’audit

4 Résultats de performance

5 Audit du classement des cultures

6 Analyse par sous groupes

7 Adéquation aux usages métiers

8 Solution technique et recommandations

9 Pilotage du projet

10 Correspondance avec les compétences évaluées

11 Conclusion et livrables

Lecture recommandée. Les sections 1, 5, 7 et 10 résument la décision métier, le résultat principal de l’audit, les conditions d’usage et les preuves associées aux compétences OpenClassrooms.

1 Synthèse décisionnelle

Agritech Answers couvre la chaîne complète d'un produit de Machine Learning : consolidation des données, entraînement suivi avec MLflow, API FastAPI, conteneur Docker, interface Streamlit, tests automatisés et CI/CD. L'audit AgriTrust évalue si cette réussite technique répond réellement au besoin métier de recommandation agricole.

Le modèle Ridge obtient une RMSE de 0,498 t/ha et un R^2 de 0,913 sur 99 975 observations de test. Ces résultats permettent un usage limité d'estimation de rendement sur le périmètre du dataset. Ils ne suffisent toutefois pas à valider le classement des cultures. Sur 20 000 contextes, Rice reste systématiquement première et l'écart moyen entre la première et la dernière culture n'est que de 0,00492 t/ha, soit 0,99 % de la RMSE.

Fonction	Décision	Motif principal
Estimation du rendement	Go limité	Bonne performance de test, mais données simulées
Comparaison de cultures	Go avec protection	Afficher une conclusion non décisive lorsque l'écart est inférieur à l'erreur
Recommandation agronomique autonome	No go	Personnalisation et validation terrain non démontrées
Recommandation de rentabilité	No go	Prix et coûts absents du modèle

Indicateurs clés

Indicateur	Résultat	Interprétation
RMSE	0,498 t/ha	Erreur quadratique moyenne sur le jeu de test
MAE	0,397 t/ha	Erreur absolue moyenne
R^2	0,913	Part de variance expliquée sur les données de test
Erreur inférieure ou égale à 1 t/ha	95,52 %	Couverture de la tolérance large
Écart moyen entre cultures	0,00492 t/ha	Signal trop faible face à l'incertitude

2 Contexte et besoins métiers

Une entreprise agritech souhaite fournir aux exploitants et conseillers agricoles un outil d'aide à la décision. La première version estime le rendement d'une parcelle et classe quatre cultures : maïs, riz, soja et blé. Avant tout déploiement élargi, l'entreprise doit vérifier la stabilité du modèle, la valeur décisionnelle du classement et les protections nécessaires contre une interprétation excessive.

Problématique

Dans quelles conditions Agritech Answers peut-il être utilisé comme aide à la décision, et quelles protections sont nécessaires pour éviter qu'une prédiction techniquement valide soit interprétée comme une recommandation fiable ?

Parties prenantes

Partie prenante	Besoin
Exploitant agricole	Comprendre l'estimation, l'incertitude et les limites
Conseiller agricole	Utiliser l'indicateur sans automatiser la décision
Responsable métier	Vérifier l'adéquation entre la promesse et les résultats
Équipe Data et ML	Mesurer les erreurs globales et locales
Équipe technique	Garantir reproductibilité, API, tests et déploiement
Direction de projet	Arbitrer les évolutions selon la valeur, le coût et le délai

Besoins prioritaires

1. Mesurer les performances globales et par sous-groupes.
2. Comparer les écarts entre cultures à l'erreur du modèle.
3. Identifier les situations dans lesquelles le système doit conclure que le classement n'est pas décisif.
4. Rendre les limites compréhensibles pour un utilisateur non technique.
5. Produire un audit reproductible et couvert par des tests.

3 Périmètre et méthode d’audit



Figure 1 Position de l’audit AgriTrust dans la chaîne existante

Architecture auditée

Domaine	Éléments existants
Données	666 494 lignes consolidées et contrôles de qualité
Modélisation	Ridge, Random Forest, HistGradientBoosting et baseline comparés
Suivi	Expériences et métriques suivies avec MLflow
API	Endpoints health, predict et recommend avec FastAPI
Produit	Interface Streamlit de prédiction et de classement
Industrialisation	Docker, GitHub Actions et publication GHCR
Qualité	14 tests initiaux complétés par 3 tests d’audit

Protocole reproductible

1. Reproduire le jeu de test avec la même graine aléatoire et la même stratification par culture.
2. Recharger le modèle sérialisé et recalculer les métriques globales.
3. Mesurer l’erreur par culture, région, sol, météo, fertilisation, irrigation et bandes climatiques.
4. Forcer successivement les quatre cultures sur un même contexte afin d’évaluer le classement.
5. Comparer l’écart inter-cultures à la RMSE et au 90e percentile de l’erreur absolue.
6. Produire les preuves JSON, CSV, graphiques et une matrice de décision go ou no-go.

L’empreinte SHA-256 du dataset reconstitué correspond à celle enregistrée pendant l’entraînement. L’environnement est verrouillé par uv.lock. Les 17 tests passent localement et dans GitHub Actions.

4 Résultats de performance

Le modèle conserve de bonnes performances sur le jeu de test isolé. L'erreur moyenne reste proche de 0,4 t/ha et 95,52 % des prédictions présentent une erreur absolue inférieure ou égale à 1 t/ha. La distribution montre cependant qu'une partie des observations dépasse nettement l'erreur médiane.

Mesure	Résultat
Observations de test	99 975
RMSE	0,4983 t/ha
MAE	0,3974 t/ha
R^2	0,9131
Erreur absolue médiane	0,3355 t/ha
Erreur absolue P90	0,8195 t/ha
Erreur absolue P95	0,9772 t/ha
Erreur inférieure ou égale à 0,5 t/ha	68,46 %
Erreur inférieure ou égale à 1 t/ha	95,52 %

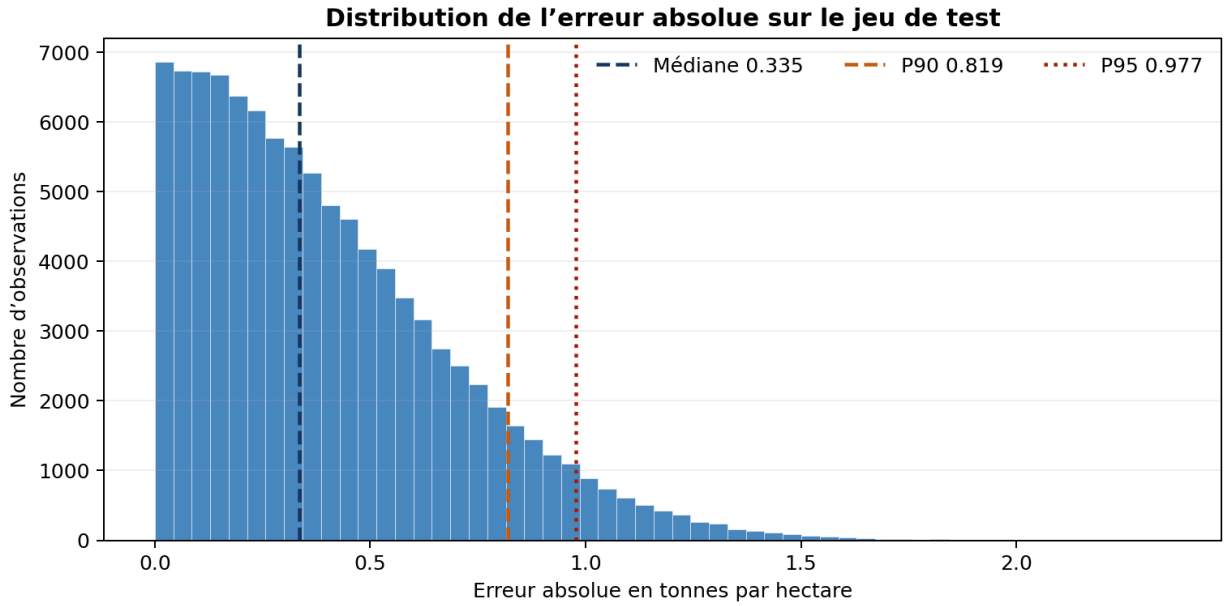


Figure 2 Distribution de l'erreur absolue sur 99 975 observations de test

5 Audit du classement des cultures

L'audit force chacune des quatre cultures tout en conservant exactement le même contexte. Si le système était réellement sensible au sol, au climat et aux pratiques, l'ordre des cultures devrait varier entre les contextes. Ce n'est pas le cas : l'ordre Rice, Soybean, Wheat, Maize apparaît dans les 20 000 scénarios étudiés.

Test	Résultat
Contextes analysés	20 000
Culture classée première	Rice dans 20 000 cas sur 20 000
Classement complet	Rice supérieur à Soybean supérieur à Wheat supérieur à Maize
Écart moyen première dernière	0,00492 t/ha
Part de l'écart dans la RMSE	0,99 %
Écarts supérieurs à la RMSE	0 %
Écarts supérieurs à l'erreur P90	0 %

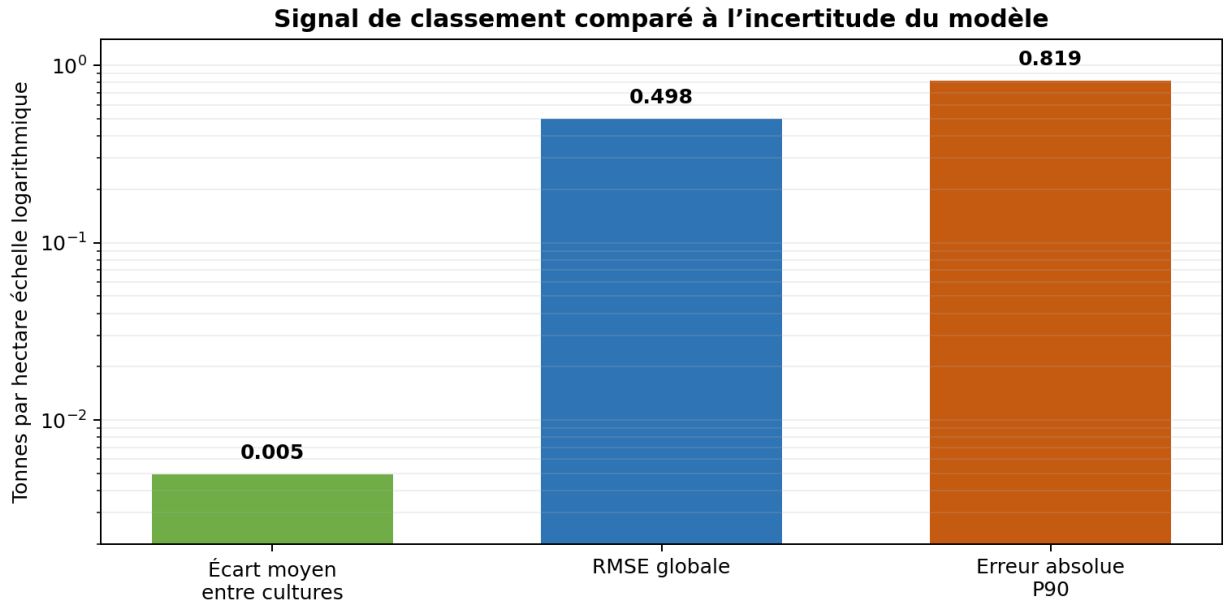


Figure 3 L'écart entre cultures est environ cent fois plus faible que la RMSE

Interprétation

Le modèle Ridge est additif et n'intègre pas d'interactions entre la culture et les variables de contexte. Le classement reflète donc un petit effet fixe associé à la catégorie Crop, et non une adaptation agronomique au contexte. Présenter la première ligne comme une meilleure culture constituerait une surinterprétation.

6 Analyse par sous groupes

Les performances ont été recalculées selon neuf dimensions. La RMSE la plus élevée est observée pour le sol argileux avec 0,5060 t/ha, contre 0,4983 t/ha globalement. Aucun effondrement majeur n'apparaît dans les sous-groupes disponibles. Cette stabilité ne prouve pas une robustesse sur de futures données réelles.

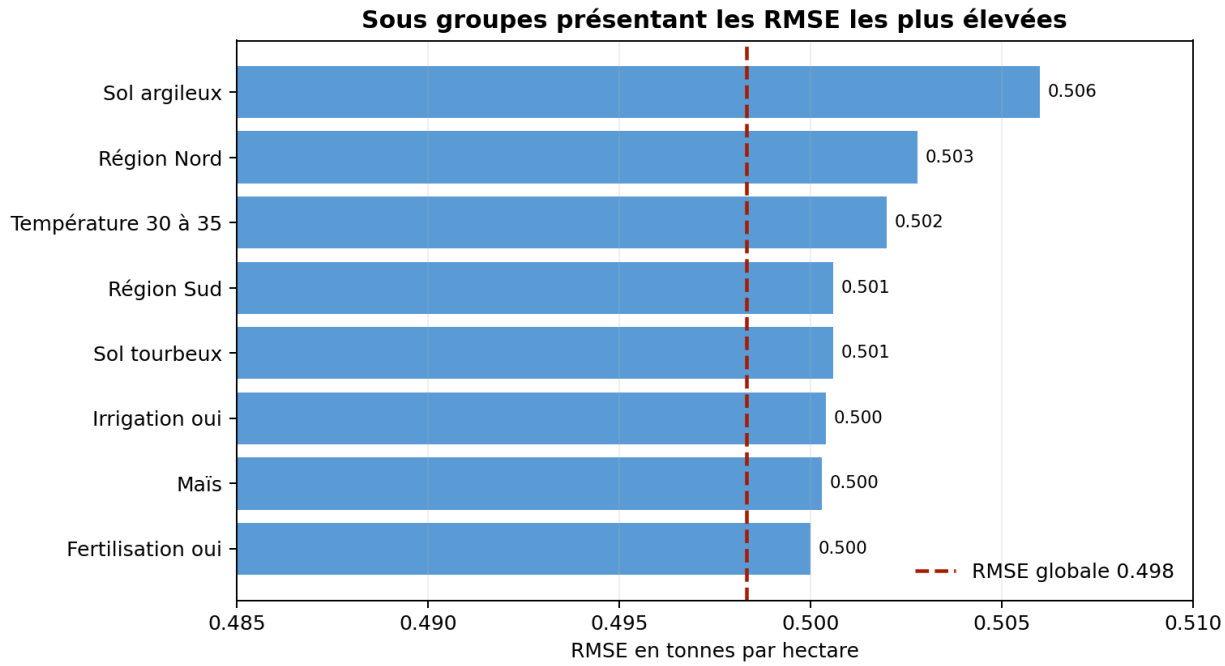


Figure 4 Les sous-groupes les plus difficiles restent proches de la RMSE globale

Dimension	Valeur	Effectif	RMSE t/ha
Type de sol	Argileux	16 608	0,5060
Région	Nord	25 020	0,5028
Température	30 à 35 degrés	19 892	0,5020
Région	Sud	24 926	0,5006
Type de sol	Tourbeux	16 701	0,5006
Irrigation	Oui	50 011	0,5004
Culture	Maïs	25 018	0,5003

7 Adéquation aux usages métiers

Usages autorisés

- Démonstration encadrée d'une estimation de rendement sur le domaine couvert par le dataset.
- Comparaison exploratoire à condition d'afficher explicitement que le classement n'est pas décisif.
- Support pédagogique pour expliquer la différence entre performance prédictive et valeur décisionnelle.
- Base technique pour une future collecte de données réelles et une validation agronomique.

Usages interdits dans la version actuelle

- Décider automatiquement quelle culture planter.
- Présenter Rice comme la meilleure culture pour tous les contextes.
- Promettre une rentabilité ou optimiser un bénéfice économique.
- Extrapoler les résultats au terrain sans validation sur des données réelles représentatives.

Limites structurantes

Limite	Conséquence	Protection
Dataset principal simulé	La performance ne valide pas l'usage terrain	Limiter la promesse et prévoir une validation réelle
Interactions absentes	Classement quasi fixe	Conclure non décisif et revoir la modélisation
Données économiques absentes	Rendement différent de rentabilité	Interdire toute promesse financière
Associations non causales	Une variation prédite ne prouve pas un effet agronomique	Maintenir un expert dans la boucle

8 Solution technique et recommandations

Solution retenue pour la version OpenClassrooms

La solution minimale conserve le produit existant et ajoute un audit reproductible. Le script d'audit recrée le jeu de test, calcule les métriques globales et locales, teste le classement sur 20 000 contextes, compare le signal décisionnel à l'incertitude et génère les preuves exploitables dans le rapport et la soutenance.

Commande d'exécution : uv run python src/audit_reliability.py

Recommandations immédiates

1. Conserver l'endpoint predict pour une démonstration encadrée.
2. Maintenir ranking_is_decisive à false lorsque l'écart est inférieur à la RMSE.
3. Ne pas afficher les expressions meilleure culture ou culture la plus rentable.
4. Présenter les cultures comme statistiquement indiscernables avec les données actuelles.
5. Utiliser l'audit AgriTrust comme contrôle avant chaque évolution du modèle ou du dataset.

Backlog professionnel et recherche après validation

Priorité	Évolution	Valeur attendue
P1	Collecter des données réelles représentatives	Mesurer la validité terrain
P1	Ajouter des variables spécifiques aux cultures	Créer un signal de personnalisation
P1	Modéliser les interactions culture sol climat	Faire varier le classement selon le contexte
P2	Estimer des intervalles de prédiction	Quantifier l'incertitude locale
P2	Détecter la dérive et le hors distribution	Sécuriser l'usage en production
P3	Ajouter prix et coûts agricoles	Étudier la rentabilité sans la confondre avec le rendement

9 Pilotage du projet

Planning accéléré

Lot	Charge cible	Livrable
Cadrage et besoins	3 h	Problématique, parties prenantes et périmètre
Audit reproductible	6 h	Script, métriques et graphiques
Analyse métier	4 h	Matrice go ou no-go et recommandations
Intégration au portfolio	5 h	Étude de cas et preuves visuelles
Carte conceptuelle	3 h	Cartographie des compétences
Rapport et soutenance	7 h	Rapport, slides et démonstration
Marge de correction	2 h	Ajustements du mentor et du template
Total	30 h	Version OpenClassrooms prête à présenter

Coûts et hypothèses

- Données, bibliothèques open source et exécution locale : coût direct marginal nul.
- Hébergement public non requis pour la version de validation.
- Valorisation indicative de 30 heures à 40 euros par heure : 1 200 euros de coût interne théorique.
- Un déploiement réel nécessiterait une estimation spécifique de l'hébergement, du monitoring, de la maintenance et de la validation agronomique.

Risques et mesures de maîtrise

Risque	Impact	Mesure de maîtrise
Surinterprétation des données simulées	Élevé	Répéter la limite dans l'interface, le rapport et la soutenance
Confusion rendement et rentabilité	Élevé	Interdire la promesse financière
Recommandation trop affirmative	Élevé	Règle de non-conclusion et validation humaine
Surdéveloppement avant la soutenance	Moyen	Séparer la version OC du backlog professionnel

10 Correspondance avec les compétences évaluées

Compétence OpenClassrooms	Preuves apportées
Collecter les besoins métiers et analyser le contexte	Problématique, parties prenantes, besoins, usages et contraintes
Auditer la solution data	Architecture V1, métriques globales, sous-groupes, limites et audit du classement
Identifier une solution technique	Script reproductible, résultats structurés, tests et règle de non-conclusion
Apporter un appui stratégique et méthodologique	Matrice go ou no-go, usages autorisés, recommandations et backlog
Contrôler délais, coûts, livrables et performance	Planning, estimation, risques, indicateurs et CI verte

Critères d'acceptation

Objectif	Critère	Statut
Reproductibilité	Dataset identifié par hash et environnement verrouillé	Atteint
Qualité logicielle	17 tests réussis localement et dans GitHub Actions	Atteint
Couverture de l'audit	Métriques globales et neuf dimensions de sous-groupes	Atteint
Fiabilité décisionnelle	Écart inter-cultures comparé à la RMSE et au P90	Atteint
Transparence	Usages autorisés et interdits documentés	Atteint
Aide à la décision	Matrice go ou no-go et recommandations priorisées	Atteint

Preuves techniques

Dépôt GitHub : agritrust-portfolio

Exécution validée : 17 tests réussis, interface Streamlit démarrée, image Docker construite et endpoints testés par la CI.

11 Conclusion et livrables

AgriTrust démontre qu'un modèle peut présenter de bonnes métriques prédictives tout en restant inadapté à la décision qu'on souhaite lui confier. L'audit ne conclut pas que le système est inutile : il délimite précisément ce qu'il sait faire, ce qu'il ne sait pas démontrer et les protections nécessaires avant tout usage réel.

La décision retenue est de conserver l'estimation de rendement comme démonstrateur encadré, de rendre toute comparaison de cultures explicitement non décisive dans la version actuelle et de refuser les promesses de recommandation agronomique autonome ou de rentabilité. Cette conclusion relie performance technique, besoin métier, gestion du risque et pilotage des évolutions.

Livrables

Livrable	Rôle
src/audit_reliability.py	Audit reproductible
tests/test_audit_reliability.py	Contrôle des métriques, du split et du classement
reports/agritrust/results/audit_summary.json	Résultats complets
reports/agritrust/results/subgroup_metrics.csv	Métriques détaillées par sous-groupes
reports/agritrust/results/executive_summary.md	Synthèse métier
reports/agritrust/results/plots	Preuves visuelles
AgriTrust Rapport Audit OC	Rapport de cadrage, audit et recommandations

Suite du projet

Après validation du rapport dans le template officiel, les prochaines productions sont la carte conceptuelle, l'étude de cas courte destinée au portfolio et la présentation de soutenance. Les évolutions de recherche et de production restent volontairement séparées du périmètre minimal de validation.