Carte conceptuelle du parcours Data Scientist

Quatre réalisations détaillées, les autres projets regroupés par compétences

VERSION OC
SYNTHÈSE DU PARCOURS

1 Analyse énergétique des bâtiments

Analyse de données et Machine Learning

Objectif : estimer la consommation annuelle sans relevé direct
Données : 1 456 bâtiments non résidentiels de Seattle
Contribution : nettoyage, variables métier, comparaison de modèles
Résultat : Random Forest, R^2 0,72 et MAE 3,39 M kBtu
Facteurs clés : usage hospitalier, étages, surface par étage
Limite : une seule année et peu de données sur les équipements

2 Déploiement d'un modèle de crédit

ML Engineering et MLOps

Objectif : exposer et superviser un modèle LightGBM
Contribution : API FastAPI, conteneur Docker et interface Gradio
Qualité : tests pytest et automatisation GitHub Actions
Monitoring : logs JSONL, dashboard Streamlit et analyse du drift
Optimisation : conversion ONNX et validation des prédictions
Résultat : inférence mesurée autour de 0,03 à 0,05 ms

BAPTISTE BONNET

Data Scientist
Machine Learning et MLOps

Systèmes data utiles, déployables et évalués avec leurs limites

3 Système RAG et évaluation LLM

IA générative et mesure de la fiabilité

Objectif : répondre à des questions métier sur des données NBA
Architecture : recherche vectorielle, routage structuré et outil SQL
Technologies : Mistral, FAISS, SQLite, Pydantic et Logfire
Évaluation : jeu de 20 questions et métriques RAGAS
Contribution : tests de robustesse, traçabilité et comparaison des versions
Apport : distinguer qualité de récupération et qualité de génération

Évolution et posture professionnelle

Au départ : rechercher la meilleure métrique
Aujourd'hui : contrôler les données, les erreurs, le monitoring et les usages autorisés

Rigueur, autonomie, analyse critique
Communication technique et métier

4 AgriTrust

Projet personnel, audit d'un système ML agricole

Base existante : MLflow, FastAPI, Docker, Streamlit et CI/CD
Audit : 99 975 observations de test, neuf axes de sous-groupes
Performance rendement : Ridge, R^2 0,913 et RMSE 0,498 t/ha
Constat : classement identique sur 20 000 contextes simulés
Décision : rendement utilisable sous conditions, recommandation autonome refusée
Preuves : script reproductible, 17 tests réussis et CI verte

Autres projets du parcours

ANALYSE ET CLASSIFICATION

Systèmes éducatifs, classification automatique d'informations

VISION ET INDUSTRIALISATION

Semi-supervisé en images, MLOps parties 1 et 2

PILOTAGE

Cadrage d'un projet IA, besoins, risques, coûts et gouvernance